PLACA 01 · INGENIERÍA Y CIENCIA DE DATOS

Pipelines de Datos y Arquitectura ETL: Fundamentos y Flujos

Síntesis conceptual y operativa basada en la guía técnica de IBM Think (Cole Stryker)

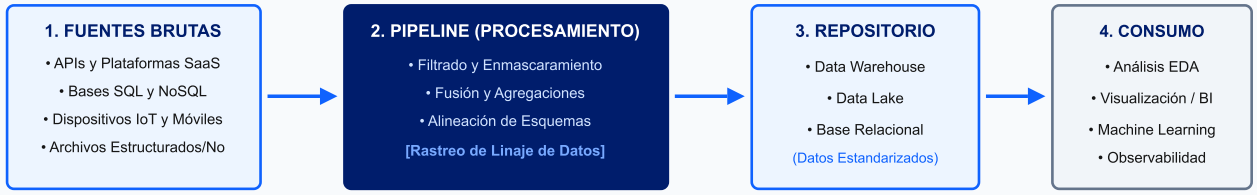
1. ¿Qué es un Pipeline en Ciencia de Datos?

CONCEPTO BASE

Un **pipeline de datos** (o canalización de datos) es un método sistemático en el que los datos sin procesar se recolectan desde múltiples orígenes, se transforman y posteriormente se trasladan hacia un almacén de datos —como un *data lake* o un *data warehouse*— para su análisis. Como su nombre lo indica, estas infraestructuras actúan como «tuberías» que abastecen proyectos de ciencia de datos y paneles de *business intelligence*, permitiendo gestionar volúmenes masivos de información de forma estructurada.

Aunque los datos pueden obtenerse de una amplia variedad de lugares (interfaces API, bases de datos SQL y NoSQL, archivos o sensores), rara vez están listos para su consumo inmediato. Antes de fluir hacia el repositorio final, se someten a transformaciones esenciales —como **filtrado, enmascaramiento y agregaciones**— que garantizan su integración y estandarización. Esto resulta crítico cuando el destino es una base de datos relacional con un esquema definido que exige coincidencia exacta de columnas y tipos de datos.

FIGURA 1.1 — FLUJO EXTREMO A EXTREMO DE UN PIPELINE EN CIENCIA DE DATOS



Gobernanza, Linaje de Datos y Rol en Ciencia de Datos

Durante el abastecimiento se realiza un seguimiento del **linaje de datos** para documentar la relación entre los activos en diversas aplicaciones empresariales y de TI (dónde residen y cómo se almacenan: *on-premises*, en un *data lake* o en un almacén). La preparación recae en los **científicos e ingenieros de datos**, quienes determinan el procesamiento requerido combinando análisis exploratorio de datos (EDA) y requisitos de negocio definidos.

2. Los 3 Pasos Fundamentales de la Arquitectura

Toda arquitectura de canalización de datos se organiza en tres etapas operativas que transforman los insumos brutos en activos listos para el consumo analítico:

1. **Recopilación de datos (Ingesta):** Los datos estructurados y no estructurados se capturan desde plataformas SaaS, dispositivos IoT y móviles (llamados *productores*, *editores* o *remitentes* en transmisión). Es una buena práctica alojar primero los datos brutos en un almacenamiento en la nube para poder actualizar datos históricos si se ajustan los trabajos de procesamiento, aplicando validaciones de coherencia y precisión.
2. **Transformación de datos:** Se ejecuta una serie de trabajos automatizados y gobernados para adaptar la información al formato exigido por el repositorio de destino. Esto asegura que los datos se limpien de forma consistente en flujos repetitivos (como reportes empresariales), permitiendo tareas como desenrollar un flujo en formato **JSON anidado** para extraer sus campos clave.
3. **Almacenamiento de datos:** Los datos ya transformados se depositan en un repositorio centralizado donde quedan expuestos a los distintos *stakeholders* (denominados *consumidores*, *suscriptores* o *destinatarios* dentro de los entornos de *streaming*).

3. Tipologías Principales de Pipelines de Datos

CLASIFICACIÓN TÉCNICA

Tipo de Pipeline	Funcionamiento y Dinámica Operativa	Tecnologías y Escenarios de Uso
Procesamiento por Lotes (Batch)	Carga «lotes» de gran volumen en intervalos programados (fuera del horario comercial para no sobrecargar el sistema). Ejecuta comandos secuenciados donde la salida de un paso es la entrada del siguiente.	Algoritmo MapReduce (2004), Hadoop, CouchDB, MongoDB. Óptimo sin urgencia inmediata (ej. contabilidad mensual) y estrechamente asociado a **ETL** .
Transmisión de Datos (Streaming)	Arquitectura basada en eventos que procesa flujos continuos con baja latencia. Agrupa acciones relacionadas en «temas» o «flujos» mediante intermediarios de mensajes.	Brokers como Apache Kafka. Esencial cuando se requieren datos en tiempo real: sensores IoT, interacciones en apps y puntos de venta (control de stock).
Integración de Datos	Se concentra en fusionar datos de múltiples sistemas dispares con formatos incompatibles en una única vista unificada, limpiando y enriqueciendo la información.	Procesos ETL hacia *data warehouses* o *data lakes*; conectores de almacenamiento de objetos como Amazon S3 en AWS.
Nativos de la Nube (Cloud-Native)	Suite de software moderno *cloud-first* que ingiere, almacena, procesa y transforma datos reduciendo silos y habilitando el autoservicio analítico.	Plataformas de datos modernas en la nube que garantizan precisión, oportunidad y confianza para analítica avanzada e IA.

> **Compromiso Técnico: Latencia vs. Confiabilidad en Streaming**
>
> Dado que los eventos se procesan poco después de ocurrir, el procesamiento de transmisión tiene menor latencia que los lotes, pero se considera menos confiable porque los mensajes pueden descartarse involuntariamente o demorarse en la fila. Los intermediarios (*message brokers*) resuelven esto mediante **acuses de recibo**, donde el consumidor confirma el procesamiento antes de eliminar el mensaje de la cola.

4. El Pipeline ETL: Extracción, Transformación y Carga PLACA 03 · DETALLE ETL

Un **pipeline ETL** (*Extract, Transform, Load*) es una subcategoría específica de los pipelines de datos diseñada para extraer datos sin procesar desde múltiples fuentes, transformarlos en un entorno de procesamiento intermedio y cargarlos finalmente en un repositorio centralizado como un *data warehouse* o una base de datos relacional. Suele operar mediante trabajos de procesamiento por lotes articulados como un flujo secuencial de comandos.

En esta secuencia, un primer comando inicia la **ingesta (Extracción)**; el siguiente comando activa el **filtrado de columnas específicas, enmascaramiento, limpieza o agregación (Transformación)**; y el comando final gestiona la **integración y escritura (Carga)** en el almacén. Esta transformación previa resulta indispensable para alinear el esquema (columnas y tipos de datos) antes de actualizar bases relacionales estructuradas.

FIGURA 3.1 — ARQUITECTURA SECUENCIAL ETL FRENTE A LA VARIANTE MODERNA ELT EN LA NUBE



5. Tres Diferencias entre Pipeline de Datos y Pipeline ETL DISTINCIÓN CONCEPTUAL

1. **Secuencia específica frente a variantes como ELT:** Aunque ambos términos suelen emplearse indistintamente, el pipeline ETL sigue un orden fijo (extraer, transformar y cargar). No todo pipeline de datos sigue esta secuencia: con el auge de herramientas nativas de la nube se popularizaron los canales **ELT (Extracción, Carga, Transformación)**, donde las transformaciones se aplican después de cargar los datos en el almacén cloud.
2. **Vínculo con el procesamiento por lotes:** Los pipelines ETL tienden a ejecutarse mediante procesamiento por lotes (*batch*), mientras que el alcance de los pipelines de datos generales es más amplio e incluye procesamiento de flujos en tiempo real (*streaming*).
3. **Necesidad de transformación:** Aunque es raro ver un pipeline de datos que no aplique transformaciones para facilitar el análisis, un pipeline de datos en su conjunto no necesariamente tiene que transformar la información al trasladarla, a diferencia de lo que ocurre obligatoriamente en un pipeline ETL.

6. Funciones Operativas del Pipeline en Ciencia de Datos

PLACA 04 · USOS Y FUNCIONES

Dentro del ciclo de vida de la ciencia de datos, los pipelines bien organizados cumplen funciones técnicas esenciales que automatizan la preparación de grandes volúmenes de información antes de su exposición analítica:

- **Filtrado y depuración:** Selección de columnas específicas y eliminación de registros irrelevantes o erróneos mediante flujos de comandos secuenciados.
- **Enmascaramiento y validación:** Ocultamiento de campos sensibles para proteger la privacidad y ejecución de comprobaciones de precisión y coherencia durante la ingesta.
- **Fusión, agregación y resumen:** Integración de múltiples fuentes incompatibles en una vista unificada con métricas consolidadas listas para consulta.
- **Estandarización y adaptación estructural:** Alineación de tipos de datos con esquemas relacionales y desenrollado de estructuras complejas como objetos JSON anidados.

7. Casos de Uso en Ciencia de Datos y Aplicaciones Comerciales APLICACIONES

1. Análisis Exploratorio de Datos (EDA)

Los científicos de datos utilizan el EDA para investigar conjuntos de datos y resumir sus características principales. Ayuda a determinar cómo manipular las fuentes para descubrir patrones, detectar anomalías, poner a prueba hipótesis y verificar suposiciones.

2. Visualizaciones de Datos

Los datos procesados alimentan cuadros, gráficos, infografías y animaciones. Estas representaciones visuales permiten comunicar relaciones de datos complejas e *insights* estratégicos de una manera clara y fácil de entender.

3. Machine Learning (IA)

Rama de la IA que emplea datos limpios y algoritmos estadísticos para imitar el aprendizaje humano. Los pipelines abastecen el entrenamiento de modelos para realizar clasificaciones, predicciones y descubrir hallazgos en minería de datos.

4. Observabilidad de los Datos

Para verificar continuamente la precisión y la seguridad de la información utilizada, la observabilidad aplica herramientas dedicadas a monitorear, rastrear y alertar tanto sobre eventos esperados como sobre anomalías en el flujo.

Impacto Estratégico en Plataformas de Datos Modernas

A medida que el *big data* continúa creciendo, la automatización y gobernanza de los pipelines de datos permite a las organizaciones eliminar los silos de información, proporcionar datos precisos y oportunos, habilitar el autoservicio y construir una base sólida para los modelos de inteligencia artificial y la toma de decisiones empresariales.